

Classificação de Anomalias em Radiografias de Tórax com CNN

Protótipo de Apresentação de Resultados

Overview

03 Introdução & Objetivo

04 Contexto do Projeto: CheXpert

05 Pré-processamento

06 Estratégia

07 Arquitetura

08 Métricas de Avaliação

09 Resultados

10 Dinâmica de Treinamento

11 Conclusões

12 Evolução

Introdução

Este projeto demonstra o desenvolvimento de uma Rede Neural Convolutacional (CNN) para a classificação multi-rótulo de 14 anomalias em radiografias de tórax do dataset CheXpert.



Objetivo

Desenvolver um modelo de classificação multi-rótulo baseado em Redes Neurais Convolucionais capaz de identificar 14 anomalias em radiografias de tórax do dataset CheXpert.

O projeto contempla todo o pipeline pré-processamento, padronização das imagens, tratamento de incertezas, construção do modelo com transfer learning e módulo de atenção, além da avaliação com métricas adequadas a dados desbalanceados. O objetivo final é obter um modelo robusto, interpretável e alinhado às particularidades do diagnóstico por imagem em cenários clínicos reais.

Contexto do Projeto

CheXpert



Dataset

Utilização do dataset CheXpert-v1.0-small, uma referência em imagens médicas torácicas.



DatasMulti-rótulo

Desafio de classificar a presença de 14 anomalias distintas em uma única imagem simultaneamente.



Desbalanceamento

Classes com alta disparidade de frequência, exigindo métricas de avaliação específicas.

Pré-processamento

- ✓ Filtragem de Imagens: Seleção exclusiva de projeções Frontal/PA para garantir consistência visual e anatômica.
- ✓ Deduplicação: Seleção aleatória de apenas 1 exame por PatientID.
- ✓ Redução de Viés: A deduplicação reduziu o dataset de 223k para ~20k imagens, evitando que o modelo aprenda a identidade do paciente.



Qualidade > Quantidade

Prioridade em dados limpos e independentes.

Estratégia

U-Zero

O CheXpert possui rótulos de incerteza (-1.0) e valores ausentes (NaN). A estratégia adotada foi a U-Zero.


Rótulo -1.0 (Incerteza) → 0.0 (Ausência)
Rótulo NaN (Ausente) → 0.0 (Ausência)

Justificativa

Simplifica o problema para uma classificação binária pura (Presença vs Ausência) e assume que, na dúvida clínica, a patologia não é evidente.

Arquitetura InceptionV3 + Atenção

- Transfer Learning: Base InceptionV3 pré-treinada no ImageNet.
- Módulo CBAM: Convolutional Block Attention Module adicionado para focar em regiões relevantes da radiografia.
- Saída: Camada densa com ativação Sigmoid para classificação multi-rótulo independente.



Métricas de Avaliação

O Problema

Em dados médicos desbalanceados, a Acurácia e a ROC AUC podem ser otimistas demais.

A Solução: PR AUC

A Área Sob a Curva Precision-Recall é a métrica principal, pois penaliza falsos positivos em classes raras.

Monitoramento

O *Early Stopping* foi configurado para monitorar o pico da PR AUC no conjunto de validação.

Resultados no Conjunto de Teste

Resultados finais obtidos após o treinamento e restauração dos melhores pesos:

Métrica	Valor	Interpretação
ROC AUC Micro	0.8069	Boa capacidade geral de separação das classes.
ROC AUC Macro	0.6774	Performance média reduzida pelas classes difíceis.
PR AUC Micro	0.4488	Métrica mais realista para a precisão do modelo.
PR AUC Macro	0.2554	Indica dificuldade significativa em classes raras.
F1 Score Macro	0.1164	Baixo recall em classes minoritárias.


Dinâmica de Treinamento

Early Stopping

O treinamento foi interrompido automaticamente para evitar *overfitting*.

Pico de Validação: PR AUC ~0.4283

Observação: A curva de validação estabilizou enquanto a de treino continuou subindo, sinalizando o momento ideal de parada.



Representação ilustrativa da Curva PR

Conclusões

Aprendizado Confirmado: O modelo aprendeu padrões relevantes, evidenciado pelo ROC AUC > 0.80 .

Desafio das Classes Raras: O baixo PR AUC Macro (0.25) confirma que o modelo prioriza classes majoritárias, um comportamento comum em datasets desbalanceados.

Estratégia U-Zero: Foi eficaz para simplificar o problema, mas pode ter introduzido ruído ao tratar incertezas clínicas como "ausência".

Atenção Visual: O uso do CBAM ajudou, mas não foi suficiente para resolver o desbalanceamento extremo.

Evolução

Item

Fine-Tuning

Descongelar mais camadas do InceptionV3 para refinar a extração de características específicas de raio-x.

Data Augmentation

Aplicar rotações e zooms para aumentar a variabilidade das classes raras.

Novas Estratégias

Testar abordagens U-Ones (incerteza = presença) ou U-Ignore (ignorar incerteza na loss).

Obrigado!