

FIAP

Faculdade de Informática e Administração Paulista

Classificação de Anomalias em Radiografias de Tórax com CNN

[Bryan Fagundes](#)

[Brenner Fagundes](#)

[Diogo Botton](#)

[Hyanka Coelho](#)

[Juliana Hungaro Fidelis](#)

1. Introdução e Objetivo

O objetivo do projeto foi construir um modelo capaz de identificar simultaneamente múltiplas anomalias em imagens de radiografia de tórax. Para isso, foram utilizadas Redes Neurais Convolucionais combinadas com técnicas de Transfer Learning, garantindo maior robustez, interpretabilidade e aderência ao contexto clínico.

O dataset CheXpert apresenta desafios característicos de aplicações médicas reais: classes altamente desbalanceadas, presença de rótulos incertos e necessidade de interpretação simultânea de múltiplas patologias em uma única imagem. Esses fatores nortearam as escolhas técnicas descritas a seguir.

2. Pré-processamento e Tratamento de Rótulos

2.1. Filtragem e Deduplicação

As etapas de preparação de dados priorizaram consistência e redução de vieses:

- **Filtragem por projeção:** foram mantidas apenas imagens Frontal/PA, garantindo padronização da posição anatômica.
- **Deduplicação por paciente:** selecionou-se um único exame por *PatientID*, reduzindo o risco de o modelo aprender características específicas de cada indivíduo. Essa medida reduziu o conjunto original (223k imagens) para aproximadamente 20k, mantendo independência entre amostras.

2.2. Estratégia de Incerteza (U-Zero)

O dataset contém rótulos incertos (-1.0) e ausentes (NaN). Para simplificar o processo de aprendizado e manter o problema como binário (presença vs. ausência), adotou-se:

- Rótulos **-1.0** → **0.0**
- Rótulos **NaN** → **0.0**

A escolha do método U-Zero assume que, na ausência de evidência clara, a patologia não está presente. Embora simples, essa abordagem reduz ruído de rótulos e facilita a convergência do modelo.

3. Arquitetura do Modelo

Foi utilizada uma combinação de Transfer Learning com mecanismos de atenção:

- **Backbone:** InceptionV3 pré-treinado no ImageNet, responsável pela extração inicial de padrões visuais relevantes.
- **Módulo de Atenção (CBAM):** incorporado para direcionar o foco da rede para regiões críticas da radiografia, aumentando a interpretabilidade e precisão.
- **Camada de saída:** função *sigmoid* para permitir previsões independentes em cada uma das 14 classes (multi-rótulo).

Essa arquitetura equilibra desempenho e capacidade de generalização

4. Métricas, Avaliação e Resultados

4.1. Métricas Seleccionadas

Em cenários de dados médicos desbalanceados, métricas clássicas como acurácia e ROC AUC podem ser excessivamente otimistas. Por isso, adotou-se:

- **PR AUC (Precision-Recall)** como métrica principal.
- **Early Stopping** monitorando o pico de PR AUC no conjunto de validação.

4.2. Resultados no Conjunto de Teste

Métrica	Valor	Interpretação
ROC AUC Micro	0.8069	Boa separação geral entre classes.
ROC AUC Macro	0.6774	Impactada por classes raras mais difíceis.
PR AUC Micro	0.4488	Métrica mais representativa de precisão real.
PR AUC Macro	0.2554	Indica dificuldade nas classes menos frequentes.
F1 Score Macro	0.1164	Mostra baixo recall em patologias minoritárias.

Os resultados demonstram que o modelo aprendeu padrões relevantes (ROC AUC > 0.80), mas enfrenta limitações importantes no reconhecimento de classes raras, um comportamento esperado diante do desbalanceamento severo do dataset e da estratégia U-Zero.

5. Evolução Proposta

As melhorias recomendadas para etapas futuras incluem:

- **Fine-Tuning:** descongelar camadas adicionais do InceptionV3 para especializar a extração de características radiológicas.
- **Data Augmentation:** aplicar rotações, zoom, leves distorções geométricas e ajustes de intensidade, com foco nas classes minoritárias.
- **Novas estratégias para incerteza:** testar U-Ones (incerteza = presença) ou U-Ignore (exclusão de amostras incertas na perda) para reduzir ruídos sem simplificar excessivamente o problema clínico.